

Présentation Stratégique

Assistant FAQ Intelligent

Étudiant : Arnaud Rambourg

Date : 12/01/2026

Version : 2.0

1. CONTEXTE & ENJEUX

La communauté de communes reçoit de nombreuses questions récurrentes (déchets, urbanisme).

Objectifs

- Réduire la charge de demandes et de réponses identiques.
- Offrir une réponse 24/7 aux citoyens.
- Moderniser l'image de la collectivité.

2. ANALYSE DU BESOIN

Cible : Citoyens (tout âge).

Contraintes

- Langage clair
- Fiabilité (pas d'erreurs légales).
- Souveraineté des données (hébergement local possible).

3. STRATÉGIE A - LLM SEUL

Principe : Prompt Système + Meta-Llama-3-8B-Instruct (⚠️)
Fiabilité : **Faible**

Points Clés

- Répond avec connaissances internes.
- "Avantages :" Simplicité, rapide.
- "Inconvénients :" Hallucinations élevées.

4. STRATÉGIE B - RAG

Principe : Prompt Système + Embeddings + Meta-Llama-3-8B-Instruct

Points Clés

- Recherche vectorielle puis génération.
- "Avantages :" Fiable, sourcé.
- "Inconvénients :" Latence, complexité.

5. STRATÉGIE C - Q&A EXTRACTIF

Principe : Prompt Système + Recherche Sémantique + roberta-base-squad2

Processus

"Copie-colle" le passage exact du document source.

6. STACK TECHNIQUE

Rôle	Technologie
Langage	Python 3.11
Framework	Hugging Face
LLM	Meta-Llama-3-8B-Instruct
Embeddings	all-MiniLM-L6-v2 (384 dims)
Base Vect.	ChromaDB (Local)
Interface	Streamlit / API

7. MODÈLES IA

Génération : Mistral-7B-Instruct

Embeddings : all-MiniLM-L6-v2 (384 dims)

Extraction : roberta-base-squad2

8. RISQUES & MITIGATIONS

Hallucinations

Solution : RAG (Sources obligatoires).

Latence

Solution : Modèles quantifiés (4-bit).

Confidentialité

Solution : Modèles locaux (Off-cloud).

9. PLANNING PRÉVISIONNEL

- **Jours 1-2** : Cadrage & Données.
- **Jours 3-5** : Dév (RAG + API).
- **Jours 6-7** : Benchmark & Déploiement.
- **Jours 8+** : Tests utilisateurs.

10. RESSOURCES & LIENS

Documentation :

- [Hugging Face Inference](#)
- [SBERT Docs](#)
- [FastAPI Tuto](#)